

Análise Exploratória de Dados: aplicando método EDA para entender os dados

Sumário

Prefácio.....	3
Escopo.....	3
Tecnologias usadas.....	4
Contato.....	4
Criando o Dicionário do Dataset.....	5
Entendendo a Estrutura dos Dados.....	5
Explorando Dados.....	7
Intervalo interquartil e calculo de assimetria dos dados.....	12
Conclusões.....	13

Prefácio

Bom, analisar dados quando não temos um processo bem definido – como, por onde devemos começar, que medidas devemos usar ou até mesmo quando devemos ou não eliminar os dados nulos – em primeira instância isso pode até mesmo ser desanimador, para isso métodos de análise inicial foram propostos para em primeiro lugar entender o comportamento do dataset¹ e com base nas descobertas propor modelos preditivos ou prescritivos. Hoje em dia temos um método bem difundido conhecido como **Exploratory Data Analysis (EDA)** este método foi desenvolvido por John Tukey em 1977,² este método consiste em usar as medidas de tendências centrais em conjunto com gráficos como gráficos de pontos, dispersão e até mesmo barras entre outros para descrever o comportamento do dataset.

Escopo

Neste projeto utilizei como base, um dataset vindo do [Kaggle](#), meu foco aqui é utilizar análise descritiva junto com método EDA para entender o comportamento dos dados, com isso fica fácil propor hipóteses para criar modelos sejam eles preditivos ou prescritivos.

1 Existe um debate interno sobre a grafia do termo, que pode ser encontrado como data set ou dataset, optei aqui por utilizar a segunda opção.

2 <https://doi.org/10.1002/9781119188230.saseas0271>

Tecnologias usadas

Para este projeto optei por não utilizar ferramentas específicas de visualização como **Power BI** ou **Google Looker Studio**, isso por que acredito que as bibliotecas de Python já irão ser suficientes para este projeto. Em todo o projeto utilizei a ide **Pycharm** em junção ao ambiente virtual criado pelo pandas, quanto as bibliotecas, apenas utilizei aquelas que são necessárias para isso. Logo abaixo você poderá ver todos os requisitos deste projeto.

Módulos Python

- Pandas
- Numpy
- Seaborn

IDE e Ambiente virtual

- Pycharm
- Condas

Contato

Caso tenha algo para incrementar com este projeto – sempre é bom ter uma segunda opinião – entre em contato através por um dos meios abaixo:

- <https://www.linkedin.com/in/diogo-santos-0a8730372/>;
- diogo.nogueira.santos@outlook.com.

Criando o Dicionário do Dataset

A definição de um dicionário é algo imprescindível para a documentação de um dataset, o dicionário é algo como a estrutura que carrega o metadado de todo o conjunto de dados, ou seja ele irá definir bons rótulos para cada variável, deixar bem claro o seu tipo para além disso ele também irá definir regras aplicáveis para cada variável como por exemplo, quantas casas decimais iremos definir para variável peso? Ou, é permitido um valor nulo para a variável nome? Temos uma questão bem importante que não paramos para pensar sobre, eu serei o único que irá trabalhar nesse conjunto de dados? Logo se torna necessário que a outra pessoal que irá ter contato com estes dados esteja a par sobre todo o dataset. O dicionário também permite descrever as variáveis quando necessário.

Tendo tudo isso em mente criei um dicionário para este projeto, ele foi criado junto com outra planilha onde criei uma tabela frequência, ambos podem ser vistos no link a seguir [recursos.xlsx](#).

Entendendo a Estrutura dos Dados

O primeiro passo a ser tomado em um estado inicial é entender a estrutura do dataset – verificar se os tipos pré-definidos para o dataset estão de acordo com os tipos definidos no dicionário, verificar se existe valores nulos, ou até mesmo duplicatas – para isso irei utilizar a função **shape**, **isnull** e **dtypes** de pandas.

```
df.shape
```

```
(705, 13)
```

```
df.dtypes
```

Student_ID	int64
Age	int64
Gender	object
Academic_Level	object

Country	object
Avg_Daily_Usage_Hours	float64
Most_Used_Platform	object
Affects_Academic_Performance	object
Sleep_Hours_Per_Night	float64
Mental_Health_Score	int64
Relationship_Status	object
Conflicts_Over_Social_Media	int64
Addicted_Score	int64

dtype: object

```
df.isnull().sum()
```


Student_ID	0
Age	0
Gender	0
Academic_Level	0
Country	0
Avg_Daily_Usage_Hours	0
Most_Used_Platform	0
Affects_Academic_Performance	0
Sleep_Hours_Per_Night	0
Mental_Health_Score	0

Com isso podemos ver que todos os tipos definidos para cada variável estão de acordo com o tipo que foi definido no dicionário, também podemos ver que não existe nem um valor nulo ou duplicado – a verificação de valores duplicados foi feita a partir da única variável que pode ser tida como “exclusiva”, logo o ID_Estudante – feito isso, podemos partir para a visualização dos dados em conjunto com a aplicação das medidas de tendências centrais.

Explorando Dados

Ao iniciar a exploração de dados podemos ter como foco principal uma única variável que pode ser usada como uma “acionador” para futuras buscas de padrões, com isso aplicaremos aqui às medidas de tendências centrais na variável **Idade** – gostaria de ressaltar aqui que todas as variáveis do dataset foram traduzidas, porém o seus respectivos conteúdos permaneceram intactos –, primeiramente precisamos entender a distribuição da variável idade entre os casos de maneira geral e separada de acordo com o gênero.

```
sns.boxplot(df, x="Idade")
```




Com isso podemos ver as seguintes características gerais no que diz respeito a Idade:

- Idade Max: 24
- Idade Min: 18
- Idade média Geral: 21
- Nem um outlier foi encontrado

Mas, também podemos querer saber como a variável idade se porta quando o fator gênero é incluído, logo temos o seguinte gráfico.

```
sns.boxplot(df, x=df['Idade'], y=df['Gênero'], hue=df['Idade'], palette='mako')
```

<Axes: xlabel='Idade', ylabel='Gênero'>



Com isso você estar se perguntando “mas não foi dito que não existiam outliers?”, e sim, de fato eles não existem, o que acontece e que cada grupo possui a sua “concentração geral de casos” ou seja, para cada grupo os valores tidos como outliers nada mais são do que casos que não pertencem ao conjunto central. Logo valores tidos como outliers nem sempre são de fato valores extremos, ou seja “tudo é relativo” depende da maneira e/ou perspectiva de como observamos o conjunto de dados.

Bom concorda comigo que nem um dos gráficos acima não nos ajudam a enxergar a distribuição dos casos em relação a sua faixa etária? Para resolver isso podemos usar os quartis para criar classes para cada faixa etária – talvez isso não seja um bom método, porém está foi a solução que encontrei no momento –, com isso vamos usar a função **np.quantile** para calcular cada quartil.

Nota!

Observe que todos os quartis foram tirados em relação a variável idade em geral.

```
Q1 = np.quantile(df['Idade'], 0.25)
```

```
Q2 = np.quantile(df['Idade'], 0.50)
```

```
Q3 = np.quantile(df['Idade'], 0.75)
```

Logo abaixo você pode ver que foram criadas 4 classes, respeitando os seguintes intervalos, assim evitando que houvesse um mesmo grupo em duas ou mais classes.

```
M1 = len(df.loc[(df['Idade'] >= 18) & (df.loc['Idade'] <= 19) & (df['Gênero'] == 'Male')])
```

```
(37)
```

```
M2 = len(df.loc[(df['Idade'] >= 20) & (df.loc['Idade'] <= 21) & (df['Gênero'] == 'Male')])
```

```
(144)
```

```
M3 = len(df.loc[(df['Idade'] >= 22) & (df.loc['Idade'] <= 23) & (df['Gênero'] == 'Male')])
```

```
(153)
```

```
M4 = len(df.loc[(df['Idade'] >= 24) & (df['Gênero'] == 'Male')])
```

```
(18)
```

O mesmo foi feito com o gênero Feminino.

```
F1 = len(df.loc[(df['Idade'] >= 18) & (df.loc['Idade'] <= 19) & (df['Gênero'] == 'Female')))
```

(140)

```
F2 = len(df.loc[(df['Idade'] >= 20) & (df.loc['Idade'] <= 21) & (df['Gênero'] == 'Female')))
```

(177)

```
F3 = len(df.loc[(df['Idade'] >= 22) & (df.loc['Idade'] <= 23) & (df['Gênero'] == 'Female')))
```

(28)

```
F4 = len(df.loc[(df['Idade'] >= 24) & (df['Gênero'] == 'Female')))
```


(8)

Você pode ver como ficou o resultado logo abaixo.

<i>Distribuição de Gêneros</i>				
Faixa	Frequência Absoluta		Frequência Relativa	
	<i>Masculino</i>	<i>Feminino</i>	<i>Feminino</i>	<i>Masculino</i>
18 - 19	37	140	0,11	0,40
20 - 21	144	177	0,41	0,50
22 - 23	153	28	0,43	0,08
24	18	8	0,05	0,02
Total	352	353	1,0	1,0

Com base na frequência absoluta foi calculado a frequência relativa junto com um mapa de calor para cada frequência para assim termos uma melhor referência da frequência dos dados. E para finalizar também foi criado um histograma, assim podemos ver de fato como as frequências se portam.

```
sns.histplot(df, x=df['Idade'], hue=df['Idade'], palette='mako', shrink=1)
```



Finalizando está parte inicial de exploração dos dados agora podemos criar correlações entre a variável gênero com o nível de escolaridade, tempo médio de uso, que quais redes cada gênero tende a ter um maior uso? Bom estas perguntas serão respondidas porém em outro relatório, o nosso maior foco aqui foi ter um primeiro contato com o conjunto de dados e entender como o dataset se portava em relação a variável idade.

Intervalo interquartil e calculo de assimetria dos dados

Apesar de não ter sido citado acima, também foi calculado o intervalo interquartil dos dados e também verificamos se havia algum tipo de assimetria no conjunto de dados – de acordo com alguns autores a ideia de simetria perfeita não é algo realmente existente, o que podemos ter é uma assimetria mais próxima daquilo que consideramos como simétrico –, logo abaixo foi definido o intervalo interquartil e o calculo do coeficiente de Gilbert Bowley.

$$IQR = Q3 - Q1$$

$$(3.0)$$

$$gb = ((Q3 - Q2) - (Q2 - Q1) / (Q3 - Q1))$$

$$(0.33)$$

Com isso podemos concluir que, nosso intervalo interquartil é igual a 3 e que não possuímos uma assimetria negativa.

Conclusões

Ao finalizar este processo inicial de exploração de dados utilizando o método EDA podemos agora partir para a análise explicatória dos dados e talvez quem sabe até mesmo aplicar algum modelo preditivo neste conjunto de dados? Bom isso deixo reservado para futuros projetos... Até uma próxima.